Comparação de modelos lineares para previsão salarial

ENG4502 – Introdução à Ciência de Dados

Daniel Cagy · Felipe Klein · Gustavo Martins

10 de novembro de 2026

Sumário

1 Introdução **1**

1.1 Contextualização 1

1.2 Pergunta de pesquisa 1

2 Plano de experimentação **2**

2.1 Dados de entrada 2

2.2 Técnicas utilizadas 3

2.3 Métricas 4

2.4 Parâmetros testados 4

2.5 Cenários experimentais 4

2.6 Apoio computacional e proveniência 5

3 Resultados **6**

3.1 Metodologia 6

3.2 Resultados 7

3.3 Visualização dos Resultados 8

3.4 Análise dos Parâmetros 9

3.5 Observações Adicionais 9

4 Conclusão **10**

4.1 Conclusões Gerais 10

4.2 Limitações do Estudo 10

4.3 Considerações Finais 10

1 Introdução

1.1 Contextualização

A previsão de salários é um problema de regressão no qual se busca estimar uma variável numérica a partir de características observadas dos indivíduos. Neste trabalho, a variável de interesse é o salário bruto, representado por `wage`, e as informações disponíveis incluem idade, ano do registro, escolaridade, estado civil, raça, classe de emprego, condição de saúde e presença de plano de saúde.

Modelos de regressão linear constituem uma abordagem inicial adequada para esse problema por apresentarem implementação simples e coeficientes interpretáveis. Entretanto, diferentes formas de utilizar as variáveis podem produzir desempenhos distintos. A regressão simples permite analisar separadamente a capacidade preditiva de cada característica, enquanto a regressão múltipla combina as informações disponíveis. O Lasso acrescenta regularização ao modelo múltiplo, podendo reduzir coeficientes e selecionar características.

O objetivo geral deste estudo é comparar essas três abordagens na previsão de `wage`. Especificamente, busca-se avaliar a capacidade preditiva isolada das características, verificar o ganho obtido pela combinação das variáveis e analisar se a regularização do Lasso melhora o desempenho ou produz um modelo mais parcimonioso.

O estudo possui finalidade preditiva e experimental. Portanto, os coeficientes e resultados encontrados não devem ser interpretados como relações causais entre as características pessoais e o salário. Essa distinção é especialmente importante porque o conjunto de dados contém atributos sensíveis, como raça, estado civil e condição de saúde.

1.2 Pergunta de pesquisa

Este trabalho busca responder à seguinte pergunta de pesquisa:

> *Qual das abordagens consideradas — regressão linear simples, regressão linear múltipla ou Lasso — apresenta o menor Erro Absoluto Médio na previsão da variável* `wage` *a partir das características disponíveis?*

2 Plano de experimentação

2.1 Dados de entrada

O dataset contém 8 variáveis preditoras e 1 variável alvo, que é o salário bruto.

Tabela 1: Variáveis preditoras

Variável	**Descrição**	**Tipo**
year	Ano do registro	Numérica
age	Idade do trabalhador	Numérica
maritl	Estado civil	Categórica
race	Raça	Categórica
education	Educação	Categórica
jobclass	Classe de emprego (Industrial ou Informática)	Categórica
health	Nível de saúde (bom ou muito bom)	Categórica
health_ins	Possui plano de saúde (sim ou não)	Categórica

O conjunto possui 3.000 observações e não apresenta valores ausentes. A coluna `Unnamed: 0`, presente no arquivo original, representa apenas o índice das observações e será descartada antes da modelagem. Após essa remoção, permanecem as oito variáveis preditoras e a variável alvo `wage`.

Tabela 2: Resumo da variável alvo `wage`

Estatística	**Valor**
Número de observações	3.000
Valores ausentes	0
Média	111,70
Mediana	104,92
Mínimo	20,09
Máximo	318,34
Observações além de 1,5 IQR	110
Observações além de 3 IQR	77

A média superior à mediana indica assimetria à direita na distribuição salarial. Entre as 110 observações situadas além de 1,5 IQR, 109 estão acima do limite superior e uma está abaixo do limite inferior. As 77 observações além de 3 IQR estão todas no extremo superior da distribuição. Essas observações serão mantidas, pois podem representar salários legítimos e sua remoção alteraria o problema de previsão definido pelo estudo.

As variáveis `year` e `age` serão tratadas como numéricas e normalizadas para o intervalo entre 0 e 1 pelo método Min-Max. As seis variáveis restantes serão tratadas como categóricas e convertidas em variáveis indicadoras por codificação *one-hot*, com a primeira categoria de cada variável utilizada como referência. Após essas transformações, o conjunto de preditores será composto por 16 colunas.

Após o pré-processamento, os dados serão divididos aleatoriamente em conjuntos de treinamento e teste, contendo, respectivamente, 80% e 20% das observações. Dessa forma, serão destinadas aproximadamente 2.400 observações ao treinamento e 600 ao teste. Será utilizada a semente aleatória 42 para permitir a reprodução da divisão, e o conjunto de teste será reservado para a avaliação final dos modelos.

2.2 Técnicas utilizadas

Optamos por comparar três abordagens de regressão linear para a previsão do salário bruto: regressão linear simples, regressão linear múltipla e regressão Lasso. Essa delimitação permite avaliar o ganho obtido pela combinação de variáveis e verificar se a regularização melhora o desempenho preditivo.

Regressão Linear. A regressão linear simples estima o salário a partir de uma única variável preditora. Para cada uma das oito variáveis disponíveis, será ajustado um modelo independente, permitindo avaliar isoladamente sua capacidade preditiva. A previsão é obtida pela combinação linear

$$\widehat{y}_i = \beta_0 + \beta_1 x_i, \tag{1}$$

em que $\widehat{y}_i$ é o salário previsto para o indivíduo i, x_i é o valor da variável preditora, β_0 é o intercepto e β_1 é o coeficiente associado à variável. Os coeficientes são estimados de modo a minimizar a soma dos quadrados dos resíduos entre os valores observados e previstos. Quando a variável preditora for categórica, suas categorias serão representadas por variáveis indicadoras.

Regressão Linear Múltipla. A regressão linear múltipla estende o modelo anterior ao empregar simultaneamente duas ou mais variáveis preditoras. Sua combinação linear é dada por

$$\widehat{y}_i = \beta_0 + \sum_{j=1}^{p} \beta_j x_{ij} = \beta_0 + \beta_1 x_{i1} + \cdots + \beta_p x_{ip}, \tag{2}$$

em que p representa o número de variáveis utilizadas, x_{ij} é o valor da variável j para o indivíduo i e β_j é seu respectivo coeficiente. Esse modelo permite considerar conjuntamente as informações disponíveis, embora pressuponha uma relação linear entre os preditores e o salário. As variáveis categóricas serão previamente representadas por variáveis indicadoras.

Regressão Lasso. O Lasso estende a regressão linear múltipla ao acrescentar uma penalização L_1 à função de ajuste. Os coeficientes são estimados pela minimização de

$$\frac{1}{2n} \sum_{i=1}^{n} (y_i - \widehat{y}_i)^2 + \alpha \sum_{j=1}^{p} \left|\beta_j\right|, \tag{3}$$

em que α controla a intensidade da regularização. Valores pequenos de α produzem resultados próximos aos da regressão linear múltipla, enquanto valores maiores reduzem os coeficientes e podem fazer com que alguns deles se tornem exatamente zero. Dessa forma, o Lasso também realiza seleção de características. Para que a penalização seja aplicada de forma comparável, serão utilizadas as variáveis previamente codificadas e normalizadas.

2.3 Métricas

O desempenho preditivo dos modelos será avaliado pelo Erro Absoluto Médio (MAE), definido por

$$\mathrm{MAE} = \frac{1}{n} \sum_{i=1}^{n} |y_i - \widehat{y}_i| \,. \tag{4}$$

Essa métrica representa a magnitude média dos erros na mesma unidade da variável salarial e possui interpretação direta. Além disso, por não elevar os resíduos ao quadrado, é menos influenciada por salários extremos. Essa característica é relevante para os dados utilizados, cuja distribuição salarial apresenta assimetria à direita. Assim, o MAE será adotado como critério para a seleção do melhor modelo: quanto menor seu valor, melhor o desempenho preditivo.

O MAE será calculado sobre observações não utilizadas no ajuste dos modelos. Na comparação por validação cruzada, serão empregadas as mesmas divisões dos dados para todas as técnicas, reportando-se a média e o desvio-padrão do MAE. Como referência, o desempenho também será comparado ao de um modelo ingênuo que prevê sempre a mediana salarial do conjunto de treinamento.

2.4 Parâmetros testados

As regressões lineares simples e múltipla serão executadas com seus parâmetros mantidos fixos, sem busca de hiperparâmetros. Serão ajustados oito modelos simples, um para cada variável preditora, e um modelo múltiplo contendo as oito variáveis.

No Lasso, serão testados 200 valores do parâmetro de regularização α, distribuídos uniformemente em escala logarítmica entre 10^{-4} e 10^{2}. O intervalo abrange desde penalizações quase nulas até penalizações capazes de reduzir diversos coeficientes a zero.

Cada configuração será avaliada por validação cruzada repetida, com cinco divisões e três repetições. Assim, cada configuração será testada em 15 partições, sempre idênticas entre as técnicas, e a seleção será baseada no menor MAE médio de validação. Ao todo, serão avaliadas 209 configurações distintas e realizados 3.135 ajustes dos modelos candidatos. O baseline da mediana será avaliado separadamente nas mesmas 15 partições, acrescentando 15 avaliações de referência.

Após a seleção do melhor valor de α, as oito regressões simples, a regressão múltipla, o melhor Lasso e o baseline serão reajustados com todo o conjunto de treinamento e avaliados uma única vez no conjunto de teste. O teste não será utilizado para escolher o valor de α nem para modificar os modelos.

2.5 Cenários experimentais

A Tabela 3 explicita as combinações entre técnicas, parâmetros e partições utilizadas no experimento. A identificação dos cenários permite relacionar cada resultado à configuração que o produziu e facilita a reprodução das comparações.

Tabela 3: Cenários definidos no plano de experimentação

Cenário	Técnica	Config.	Aval./config.	Ajustes
Baseline	Mediana do treinamento	1	15	15
S1–S8	Regressão linear simples	8	15	120
M1	Regressão linear múltipla	1	15	15
L1–L200	Lasso	200	15	3.000
Modelos candidatos		209	15	3.135

2.6 Apoio computacional e proveniência

Os experimentos serão gerenciados pelo MLflow, com banco SQLite e armazenamento local de artefatos. Para cada execução serão registrados a técnica, os parâmetros, a variável original utilizada, o caminho do conjunto de dados, a variável alvo, o protocolo de validação, as etapas de pré-processamento, a semente aleatória, o número de características, os tempos de ajuste e as métricas de treinamento, validação e teste. Também serão armazenados os coeficientes, as tabelas de resultados e os gráficos produzidos.

A reprodutibilidade será apoiada pela semente 42, pelo arquivo `requirements.txt` com as versões das dependências e por um artefato do MLflow contendo as versões do Python, pandas, NumPy, scikit-learn e MLflow. O conjunto de teste permanecerá isolado durante a escolha das configurações, evitando que seus resultados influenciem a seleção do modelo.

O código-fonte, o notebook executado, o relatório e os arquivos necessários para reprodução do estudo estão disponíveis no repositório previsao-salarial-modelos-lineares no GitHub. A planilha `results/rodadas_mlflow.xlsx` complementa o rastreamento ao apresentar, em formato tabular, as 3.150 avaliações individuais realizadas nas partições da validação cruzada, incluindo o baseline.

3 Resultados

3.1 Metodologia

Após o pré-processamento, os dados foram separados aleatoriamente em 80% para treinamento e 20% para teste, utilizando a semente 42. Dessa forma, 2.400 observações foram destinadas ao treinamento e 600 ao teste. O conjunto de treinamento foi empregado no ajuste e na seleção dos modelos, enquanto o conjunto de teste permaneceu reservado para a avaliação final.

No conjunto de treinamento, as configurações foram comparadas por validação cruzada repetida, com cinco divisões e três repetições. Foram avaliadas oito regressões lineares simples, uma regressão linear múltipla e 200 configurações do Lasso, correspondentes aos diferentes valores de α. Para as variáveis categóricas, cada regressão simples utilizou conjuntamente todas as variáveis indicadoras derivadas da característica original. As mesmas 15 partições foram utilizadas em todas as comparações, e o desempenho foi resumido pela média e pelo desvio-padrão do MAE.

As 209 configurações candidatas produziram 3.135 ajustes internos: 120 para as regressões simples, 15 para a regressão múltipla e 3.000 para o Lasso. O baseline da mediana foi avaliado separadamente nas mesmas 15 partições. Além do MAE de validação, foi calculado o MAE de treinamento e a diferença entre ambos, utilizada como indicação da capacidade de generalização.

O valor de α do Lasso foi selecionado exclusivamente pelo menor MAE médio de validação. Em seguida, as oito regressões simples, a regressão múltipla, o Lasso com o α selecionado e o baseline foram reajustados com todo o conjunto de treinamento e avaliados uma única vez no conjunto de teste.

Os experimentos foram rastreados no experimento `previsao_wage_repeated_cv` do MLflow 3.18, utilizando um banco SQLite local e armazenamento local de artefatos. Foram concluídas 212 execuções: 200 configurações filhas do Lasso, uma execução principal da busca, oito regressões simples, uma regressão múltipla, um baseline e um resumo final. Foram registrados parâmetros, proveniência dos dados, versões do ambiente, MAE de treinamento, validação e teste, diferença de generalização, tempo de ajuste, coeficientes e artefatos gráficos.

3.2 Resultados

Tabela 4: Desempenho preditivo dos modelos

Modelo	Treino	CV	DP CV	Gap	Teste
Regressão linear múltipla	23,22	23,43	1,21	0,22	22,14
Lasso	23,20	23,40	1,18	0,20	22,21
Simples: educação	25,65	25,73	1,32	0,08	24,13
Simples: plano de saúde	28,04	28,08	1,41	0,04	26,69
Simples: estado civil	28,17	28,27	1,22	0,10	27,86
Baseline da mediana	29,28	29,33	1,45	0,05	28,32
Simples: classe de emprego	29,15	29,21	1,22	0,06	28,48
Simples: raça	29,44	29,49	1,37	0,05	28,71
Simples: idade	28,82	28,86	1,20	0,04	28,77
Simples: saúde	29,34	29,36	1,34	0,03	28,99
Simples: ano	29,70	29,73	1,36	0,03	29,04

Na Tabela 4, o *gap* corresponde à diferença entre o MAE médio de validação e o MAE médio de treinamento. Valores positivos indicam erro maior nas observações não utilizadas no ajuste.

A regressão linear múltipla apresentou o menor MAE no conjunto de teste, com valor de 22,14. Em relação ao baseline da mediana, cujo MAE foi 28,32, houve uma redução absoluta de 6,18 e uma melhora relativa de aproximadamente 21,8%. O Lasso obteve resultado muito próximo, com MAE de teste igual a 22,21. Entre as regressões simples, a variável educação apresentou o melhor desempenho, com MAE de 24,13.

Na validação cruzada repetida, o Lasso apresentou o menor MAE médio, 23,40, contra 23,43 da regressão múltipla. A diferença de apenas 0,03 é pequena em relação aos desvios-padrão observados, indicando desempenhos praticamente equivalentes durante a validação. No teste, a regressão múltipla superou o Lasso por apenas 0,07 unidade de `wage`.

3.3 Visualização dos Resultados

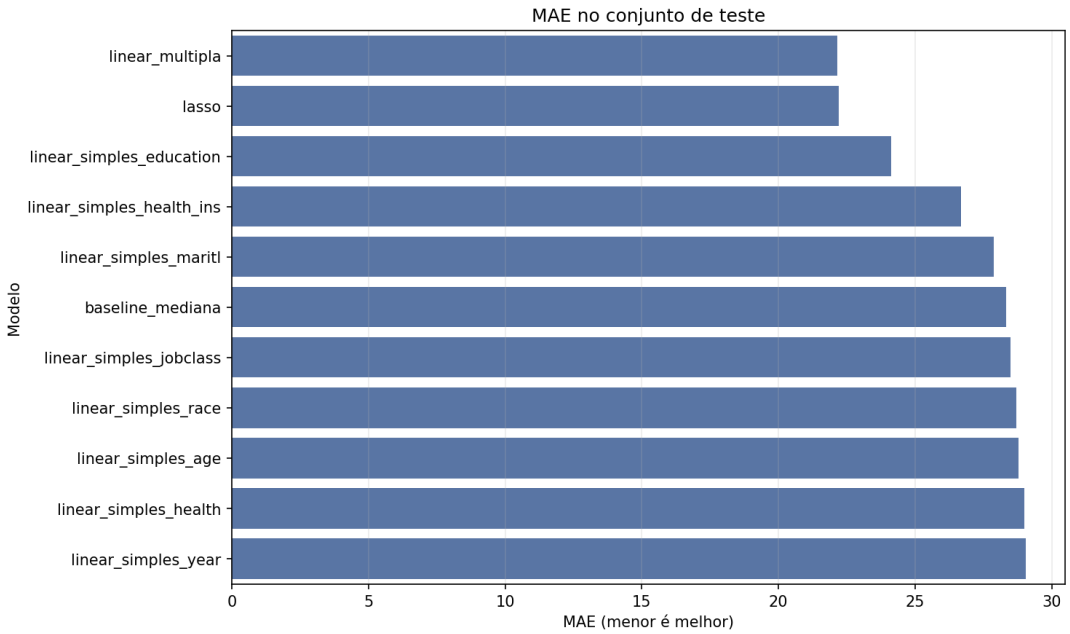


Figura 1: Comparação do MAE no conjunto de teste.

A Figura 1 evidencia a proximidade entre a regressão múltipla e o Lasso, bem como a vantagem de ambas sobre os modelos simples e o baseline. O ganho obtido pela regressão simples baseada em educação também é visível, embora seu erro ainda seja cerca de duas unidades superior ao dos modelos que combinam todas as características.

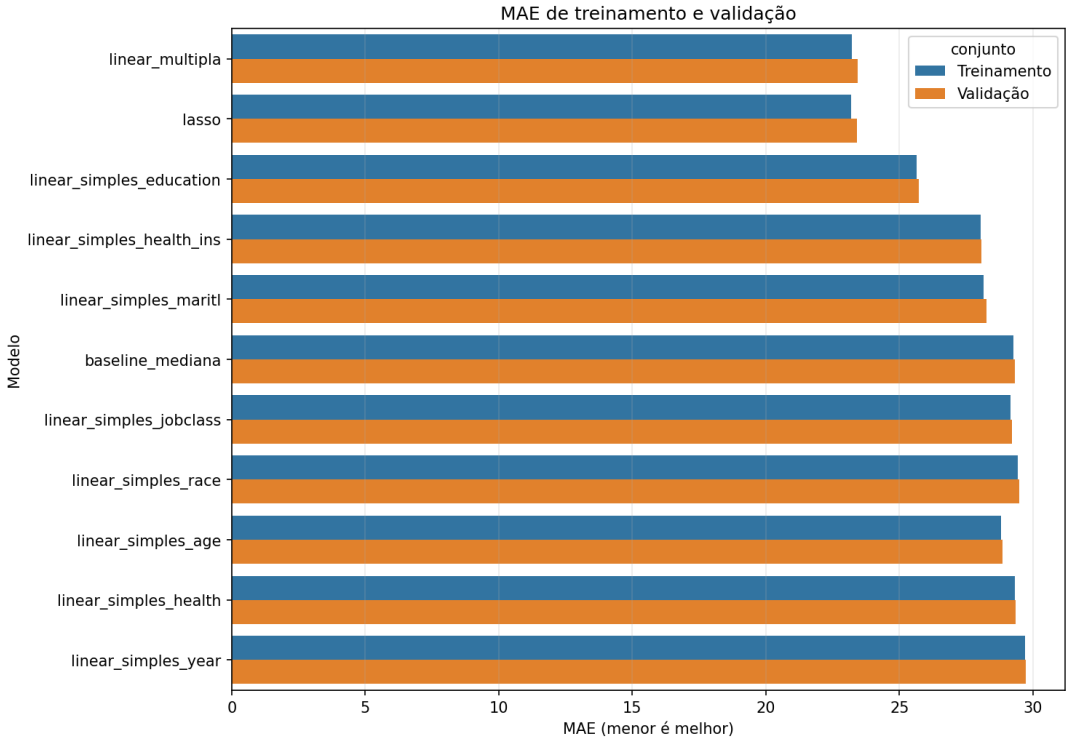


Figura 2: Comparação do MAE médio de treinamento e validação nas 15 partições.

A Figura 2 mostra diferenças pequenas entre os erros de treinamento e validação. As maiores diferenças foram observadas na regressão múltipla (0,22) e no Lasso (0,20), valores reduzidos diante da magnitude do MAE e dos respectivos desvios-padrão. Portanto, não foi identificado sinal relevante de sobreajuste nas técnicas avaliadas.

3.4 Análise dos Parâmetros

O melhor valor encontrado para o parâmetro de regularização do Lasso foi $\alpha = 0{,}063682$. Como mostra a Figura 3, valores muito pequenos produziram desempenho semelhante ao da regressão múltipla, enquanto penalizações elevadas aumentaram substancialmente o MAE por reduzirem excessivamente os coeficientes. A faixa sombreada representa um desvio-padrão entre as 15 avaliações de cada valor de α.

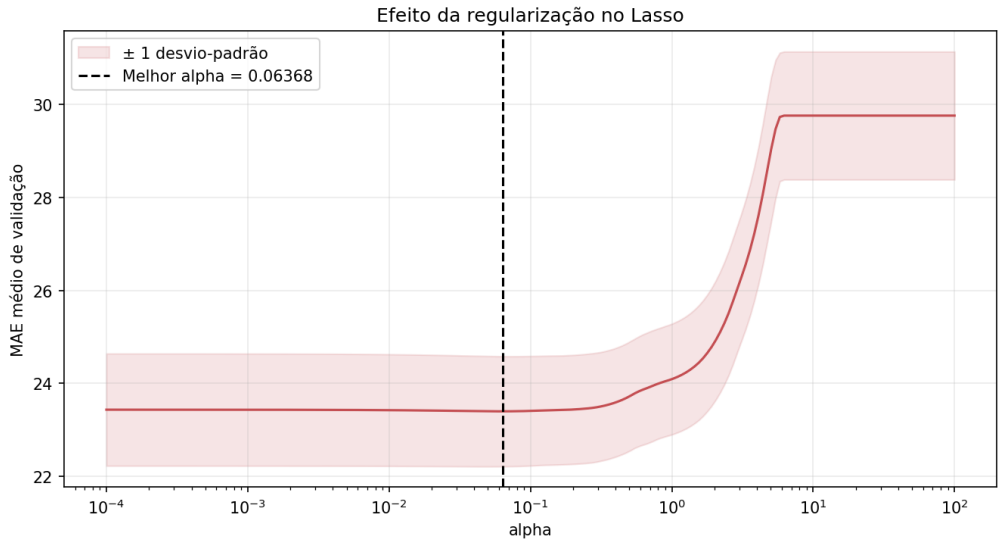


Figura 3: Relação entre o parâmetro α e o MAE médio de validação do Lasso.

Com o melhor α, somente um dos 16 coeficientes foi reduzido exatamente a zero: o indicador correspondente à categoria viúvo do estado civil. Os coeficientes de maior magnitude foram associados a pós-graduação ou formação avançada (48,57), graduação universitária (27,65), idade normalizada (20,22), ausência de plano de saúde ($-17{,}24$), estado civil casado (15,49) e alguma formação universitária (13,39). Esses valores devem ser interpretados em relação às categorias de referência utilizadas na codificação.

3.5 Observações Adicionais

Todos os 200 valores de α foram avaliados sem erro de convergência. A repetição da validação reduziu a dependência de uma única partição interna, e a pequena diferença entre os resultados de treinamento e validação sugere estabilidade razoável. Entretanto, a proximidade entre a regressão múltipla e o Lasso não permite afirmar que a regularização trouxe ganho preditivo relevante neste conjunto de dados.

Educação foi a variável isolada mais informativa, mas a combinação das oito características reduziu ainda mais o erro. Ano, saúde, idade, raça e classe de emprego, quando utilizados isoladamente, não superaram o baseline no conjunto de teste ou apresentaram diferença muito pequena em relação a ele.

4 Conclusão

4.1 Conclusões Gerais

A regressão linear múltipla apresentou o melhor desempenho no conjunto de teste, com MAE de 22,14, seguida pelo Lasso, com MAE de 22,21. Ambas superaram de forma substancial o baseline baseado na mediana, cujo MAE foi 28,32. Portanto, a combinação das oito características disponíveis permitiu reduzir o erro absoluto em aproximadamente 21,8% em relação à referência ingênua.

Entre as regressões simples, educação foi a variável com maior capacidade preditiva, alcançando MAE de 24,13. O resultado mostra que essa característica concentra parte importante da informação salarial, mas também que a incorporação conjunta das demais variáveis melhora a previsão.

O Lasso selecionou $\alpha = 0{,}063682$ e zerou apenas um dos 16 coeficientes. Sua regularização não produziu vantagem relevante sobre a regressão múltipla: o Lasso foi ligeiramente melhor na validação cruzada, enquanto a regressão múltipla foi ligeiramente melhor no teste. Considerando a diferença reduzida, os modelos apresentaram desempenhos essencialmente equivalentes, e a regressão múltipla pode ser preferida por sua simplicidade e pelo menor MAE final.

4.2 Limitações do Estudo

Embora a validação interna tenha utilizado cinco divisões e três repetições, os resultados finais ainda correspondem a uma única divisão externa entre treinamento e teste e podem variar com outra amostra. Além disso, foram consideradas apenas relações lineares e aditivas, sem termos de interação ou transformações não lineares. A interpretação dos coeficientes também depende da normalização e das categorias de referência adotadas.

O conjunto de dados possui somente 3.000 observações e inclui características sensíveis, como raça, estado civil e saúde. Assim, o desempenho preditivo não deve ser interpretado como justificativa para decisões salariais automatizadas ou para relações causais entre essas características e o salário.

4.3 Considerações Finais

O estudo respondeu à pergunta de pesquisa ao demonstrar que modelos lineares conseguem prever parcialmente a variável `wage` a partir das oito características disponíveis. A regressão múltipla apresentou o menor erro de teste, enquanto o Lasso mostrou que quase todas as características conservaram alguma contribuição no modelo regularizado.