# Previsão salarial

Relatório de modelagem preditiva

Daniel Cagy · Felipe Klein · Gustavo Martins

10 de novembro de 2026

## Sumário


**1 Introdução** **1**

1.1 Contextualização . . . . . 1

1.2 Pergunta de pesquisa . . . . . 1

**2 Plano de experimentação** **2**

2.1 Dados de entrada . . . . . 2

2.2 Técnicas utilizadas . . . . . 3

2.3 Métricas . . . . . 4

2.4 Parâmetros testados . . . . . 4

2.5 Cenários experimentais . . . . . 4

2.6 Apoio computacional e proveniência . . . . . 5

**3 Resultados** **6**

3.1 Metodologia . . . . . 6

3.2 Resultados . . . . . 7

3.3 Visualização dos Resultados . . . . . 8

3.4 Análise dos Parâmetros . . . . . 9

3.5 Observações Adicionais . . . . . 9

**4 Conclusão** **10**

4.1 Conclusões Gerais . . . . . 10

4.2 Limitações do Estudo . . . . . 10

4.3 Considerações Finais . . . . . 10

# 1 Introdução

## 1.1 Contextualização

A previsão de salários é um problema de regressão no qual se busca estimar uma variável numérica a partir de características observadas dos indivíduos. Neste trabalho, a variável de interesse é o salário bruto, representado por `wage`, e as informações disponíveis incluem idade, ano do registro, escolaridade, estado civil, raça, classe de emprego, condição de saúde e presença de plano de saúde.

Modelos de regressão linear constituem uma abordagem inicial adequada para esse problema por apresentarem implementação simples e coeficientes interpretáveis. Entretanto, diferentes formas de utilizar as variáveis podem produzir desempenhos distintos. A regressão simples permite analisar separadamente a capacidade preditiva de cada característica, enquanto a regressão múltipla combina as informações disponíveis. O Lasso acrescenta regularização ao modelo múltiplo, podendo reduzir coeficientes e selecionar características.

O objetivo geral deste estudo é comparar essas três abordagens na previsão de `wage`. Especificamente, busca-se avaliar a capacidade preditiva isolada das características, verificar o ganho obtido pela combinação das variáveis e analisar se a regularização do Lasso melhora o desempenho ou produz um modelo mais parcimonioso.

O estudo possui finalidade preditiva e experimental. Portanto, os coeficientes e resultados encontrados não devem ser interpretados como relações causais entre as características pessoais e o salário. Essa distinção é especialmente importante porque o conjunto de dados contém atributos sensíveis, como raça, estado civil e condição de saúde.

## 1.2 Pergunta de pesquisa

Este trabalho busca responder à seguinte pergunta de pesquisa:

> *Qual das abordagens consideradas — regressão linear simples, regressão linear múltipla ou Lasso — apresenta o menor Erro Absoluto Médio na previsão da variável* `wage` *a partir das características disponíveis?*

## 2 Plano de experimentação

### 2.1 Dados de entrada

O dataset contém 8 variáveis preditoras e 1 variável alvo, que é o salário bruto.

Tabela 1: Variáveis preditoras

| **Variável** | **Descrição** | **Tipo** |
|---|---|---|
| year | Ano do registro | Numérica |
| age | Idade do trabalhador | Numérica |
| maritl | Estado civil | Categórica |
| race | Raça | Categórica |
| education | Educação | Categórica |
| jobclass | Classe de emprego (Industrial ou Informática) | Categórica |
| health | Nível de saúde (bom ou muito bom) | Categórica |
| health_ins | Possui plano de saúde (sim ou não) | Categórica |

O conjunto possui 3.000 observações e não apresenta valores ausentes. A coluna `Unnamed: 0`, presente no arquivo original, representa apenas o índice das observações e será descartada antes da modelagem. Após essa remoção, permanecem as oito variáveis preditoras e a variável alvo `wage`.

Tabela 2: Resumo da variável alvo `wage`

| **Estatística** | **Valor** |
|---|---|
| Número de observações | 3.000 |
| Valores ausentes | 0 |
| Média | 111,70 |
| Mediana | 104,92 |
| Mínimo | 20,09 |
| Máximo | 318,34 |
| Observações além de 1,5 IQR | 110 |
| Observações além de 3 IQR | 77 |

A média superior à mediana indica assimetria à direita na distribuição salarial. Entre as 110 observações situadas além de 1,5 IQR, 109 estão acima do limite superior e uma está abaixo do limite inferior. As 77 observações além de 3 IQR estão todas no extremo superior da distribuição. Essas observações serão mantidas, pois podem representar salários legítimos e sua remoção alteraria o problema de previsão definido pelo estudo.

As variáveis `year` e `age` serão tratadas como numéricas e normalizadas para o intervalo entre 0 e 1 pelo método Min-Max. As seis variáveis restantes serão tratadas como categóricas e convertidas em variáveis indicadoras por codificação *one-hot*, com a primeira categoria de cada variável utilizada como referência. Após essas transformações, o conjunto de preditores será composto por 16 colunas.

Após o pré-processamento, os dados serão divididos aleatoriamente em conjuntos de treinamento e teste, contendo, respectivamente, 80% e 20% das observações. Dessa forma, serão destinadas aproximadamente 2.400 observações ao treinamento e 600 ao teste. Será utilizada a semente aleatória 42 para permitir a reprodução da divisão, e o conjunto de teste será reservado para a avaliação final dos modelos.

### 2.2 Técnicas utilizadas

Optamos por comparar três abordagens de regressão linear para a previsão do salário bruto: regressão linear simples, regressão linear múltipla e regressão Lasso. Essa delimitação permite avaliar o ganho obtido pela combinação de variáveis e verificar se a regularização melhora o desempenho preditivo.

**Regressão Linear.** A regressão linear simples estima o salário a partir de uma única variável preditora. Para cada uma das oito variáveis disponíveis, será ajustado um modelo independente, permitindo avaliar isoladamente sua capacidade preditiva. A previsão é obtida pela combinação linear

$$\widehat{y}_i = \beta_0 + \beta_1 x_i, \tag{1}$$

em que $\widehat{y}_i$ é o salário previsto para o indivíduo $i$, $x_i$ é o valor da variável preditora, $\beta_0$ é o intercepto e $\beta_1$ é o coeficiente associado à variável. Os coeficientes são estimados de modo a minimizar a soma dos quadrados dos resíduos entre os valores observados e previstos. Quando a variável preditora for categórica, suas categorias serão representadas por variáveis indicadoras.

**Regressão Linear Múltipla.** A regressão linear múltipla estende o modelo anterior ao empregar simultaneamente duas ou mais variáveis preditoras. Sua combinação linear é dada por

$$\widehat{y}_i = \beta_0 + \sum_{j=1}^{p} \beta_j x_{ij} = \beta_0 + \beta_1 x_{i1} + \cdots + \beta_p x_{ip}, \tag{2}$$

em que $p$ representa o número de variáveis utilizadas, $x_{ij}$ é o valor da variável $j$ para o indivíduo $i$ e $\beta_j$ é seu respectivo coeficiente. Esse modelo permite considerar conjuntamente as informações disponíveis, embora pressuponha uma relação linear entre os preditores e o salário. As variáveis categóricas serão previamente representadas por variáveis indicadoras.

**Regressão Lasso.** O Lasso estende a regressão linear múltipla ao acrescentar uma penalização $L_1$ à função de ajuste. Os coeficientes são estimados pela minimização de

$$\sum_{i=1}^{n} (y_i - \widehat{y}_i)^2 + \alpha \sum_{j=1}^{p} \left|\beta_j\right|, \tag{3}$$

em que $\alpha$ controla a intensidade da regularização. Valores pequenos de $\alpha$ produzem resultados próximos aos da regressão linear múltipla, enquanto valores maiores reduzem os coeficientes e podem fazer com que alguns deles se tornem exatamente zero. Dessa forma, o Lasso também realiza seleção de características. Para que a penalização seja aplicada de forma comparável, serão utilizadas as variáveis previamente codificadas e normalizadas.

### 2.3 Métricas

O desempenho preditivo dos modelos será avaliado pelo Erro Absoluto Médio (MAE), definido por

$$\mathrm{MAE} = \frac{1}{n} \sum_{i=1}^{n} |y_i - \widehat{y}_i| \,. \tag{4}$$

Essa métrica representa a magnitude média dos erros na mesma unidade da variável salarial e possui interpretação direta. Além disso, por não elevar os resíduos ao quadrado, é menos influenciada por salários extremos. Essa característica é relevante para os dados utilizados, cuja distribuição salarial apresenta assimetria à direita. Assim, o MAE será adotado como critério para a seleção do melhor modelo: quanto menor seu valor, melhor o desempenho preditivo.

O MAE será calculado sobre observações não utilizadas no ajuste dos modelos. Na comparação por validação cruzada, serão empregadas as mesmas divisões dos dados para todas as técnicas, reportando-se a média e o desvio-padrão do MAE. Como referência, o desempenho também será comparado ao de um modelo ingênuo que prevê sempre a mediana salarial do conjunto de treinamento.

### 2.4 Parâmetros testados

As regressões lineares simples e múltipla não possuem hiperparâmetros. Serão ajustados oito modelos simples, um para cada variável preditora, e um modelo múltiplo contendo as oito variáveis.

No Lasso, serão testados 200 valores do parâmetro de regularização $\alpha$, distribuídos uniformemente em escala logarítmica entre $10^{-4}$ e $10^{2}$. O intervalo abrange desde penalizações quase nulas até penalizações capazes de reduzir diversos coeficientes a zero.

Cada configuração será avaliada por validação cruzada repetida, com cinco divisões e três repetições. Assim, cada configuração será testada em 15 partições, sempre idênticas entre as técnicas, e a seleção será baseada no menor MAE médio de validação. Ao todo, serão avaliadas 209 configurações distintas e realizados 3.135 ajustes dos modelos candidatos. O baseline da mediana será avaliado separadamente nas mesmas 15 partições, acrescentando 15 avaliações de referência.

Após a seleção, a melhor configuração será reajustada com todo o conjunto de treinamento e avaliada uma única vez no conjunto de teste.

### 2.5 Cenários experimentais

A Tabela 3 explicita as combinações entre técnicas, parâmetros e partições utilizadas no experimento. A identificação dos cenários permite relacionar cada resultado à configuração que o produziu e facilita a reprodução das comparações.

Tabela 3: Cenários definidos no plano de experimentação

| Cenário | Técnica | Config. | Aval./config. | Ajustes |
|---|---|---|---|---|
| Baseline | Mediana do treinamento | 1 | 15 | 15 |
| S1–S8 | Regressão linear simples | 8 | 15 | 120 |
| M1 | Regressão linear múltipla | 1 | 15 | 15 |
| L1–L200 | Lasso | 200 | 15 | 3.000 |
| Modelos candidatos | | 209 | 15 | 3.135 |

### 2.6 Apoio computacional e proveniência

Os experimentos serão gerenciados pelo MLflow, com banco SQLite e armazenamento local de artefatos. Para cada execução serão registrados a técnica, os parâmetros, a variável original utilizada, o caminho do conjunto de dados, a variável alvo, o protocolo de validação, as etapas de pré-processamento, a semente aleatória, o número de características, os tempos de ajuste e as métricas de treinamento, validação e teste. Também serão armazenados os coeficientes, as tabelas de resultados e os gráficos produzidos.

A reprodutibilidade será apoiada pela semente 42, pelo arquivo `requirements.txt` com as versões das dependências e por um artefato do MLflow contendo as versões do Python, pandas, NumPy, scikit-learn e MLflow. O conjunto de teste permanecerá isolado durante a escolha das configurações, evitando que seus resultados influenciem a seleção do modelo.

# 3 Resultados

## 3.1 Metodologia

Após o pré-processamento, os dados foram separados aleatoriamente em 80% para treinamento e 20% para teste, utilizando a semente 42. Dessa forma, 2.400 observações foram destinadas ao treinamento e 600 ao teste. O conjunto de treinamento foi empregado no ajuste e na seleção dos modelos, enquanto o conjunto de teste permaneceu reservado para a avaliação final.

No conjunto de treinamento, as configurações foram comparadas por validação cruzada repetida, com cinco divisões e três repetições. Foram avaliadas oito regressões lineares simples, uma regressão linear múltipla e 200 configurações do Lasso, correspondentes aos diferentes valores de $\alpha$. Para as variáveis categóricas, cada regressão simples utilizou conjuntamente todas as variáveis indicadoras derivadas da característica original. As mesmas 15 partições foram utilizadas em todas as comparações, e o desempenho foi resumido pela média e pelo desvio-padrão do MAE.

As 209 configurações candidatas produziram 3.135 ajustes internos: 120 para as regressões simples, 15 para a regressão múltipla e 3.000 para o Lasso. O baseline da mediana foi avaliado separadamente nas mesmas 15 partições. Além do MAE de validação, foi calculado o MAE de treinamento e a diferença entre ambos, utilizada como indicação da capacidade de generalização.

Para cada técnica, foi selecionada a configuração com menor MAE médio. O modelo escolhido foi então reajustado com todo o conjunto de treinamento e avaliado uma única vez no conjunto de teste. Também foi avaliado um modelo de referência que prevê sempre a mediana salarial do conjunto de treinamento.

Os experimentos foram rastreados no experimento `previsao_wage_repeated_cv` do MLflow 3.18, utilizando um banco SQLite local e armazenamento local de artefatos. Foram concluídas 212 execuções: 200 configurações filhas da busca do Lasso, as execuções das demais técnicas, a execução principal da busca e um resumo final. Foram registrados parâmetros, proveniência dos dados, versões do ambiente, MAE de treinamento, validação e teste, diferença de generalização, tempo de ajuste, coeficientes e artefatos gráficos.

### 3.2 Resultados

Tabela 4: Desempenho preditivo dos modelos

| Modelo | Treino | CV | DP CV | Dif. | Teste |
|---|---|---|---|---|---|
| Regressão linear múltipla | 23,22 | 23,43 | 1,21 | 0,22 | 22,14 |
| Lasso | 23,20 | 23,40 | 1,18 | 0,20 | 22,21 |
| Simples: educação | 25,65 | 25,73 | 1,32 | 0,08 | 24,13 |
| Simples: plano de saúde | 28,04 | 28,08 | 1,41 | 0,04 | 26,69 |
| Simples: estado civil | 28,17 | 28,27 | 1,22 | 0,10 | 27,86 |
| Baseline da mediana | 29,28 | 29,33 | 1,45 | 0,05 | 28,32 |
| Simples: classe de emprego | 29,15 | 29,21 | 1,22 | 0,06 | 28,48 |
| Simples: raça | 29,44 | 29,49 | 1,37 | 0,05 | 28,71 |
| Simples: idade | 28,82 | 28,86 | 1,20 | 0,04 | 28,77 |
| Simples: saúde | 29,34 | 29,36 | 1,34 | 0,03 | 28,99 |
| Simples: ano | 29,70 | 29,73 | 1,36 | 0,03 | 29,04 |

A regressão linear múltipla apresentou o menor MAE no conjunto de teste, com valor de 22,14. Em relação ao baseline da mediana, cujo MAE foi 28,32, houve uma redução absoluta de 6,18 e uma melhora relativa de aproximadamente 21,8%. O Lasso obteve resultado muito próximo, com MAE de teste igual a 22,21. Entre as regressões simples, a variável educação apresentou o melhor desempenho, com MAE de 24,13.

Na validação cruzada repetida, o Lasso apresentou o menor MAE médio, 23,40, contra 23,43 da regressão múltipla. A diferença de apenas 0,03 é pequena em relação aos desvios-padrão observados, indicando desempenhos praticamente equivalentes durante a validação. No teste, a regressão múltipla superou o Lasso por apenas 0,07 unidade de `wage`.

### 3.3 Visualização dos Resultados

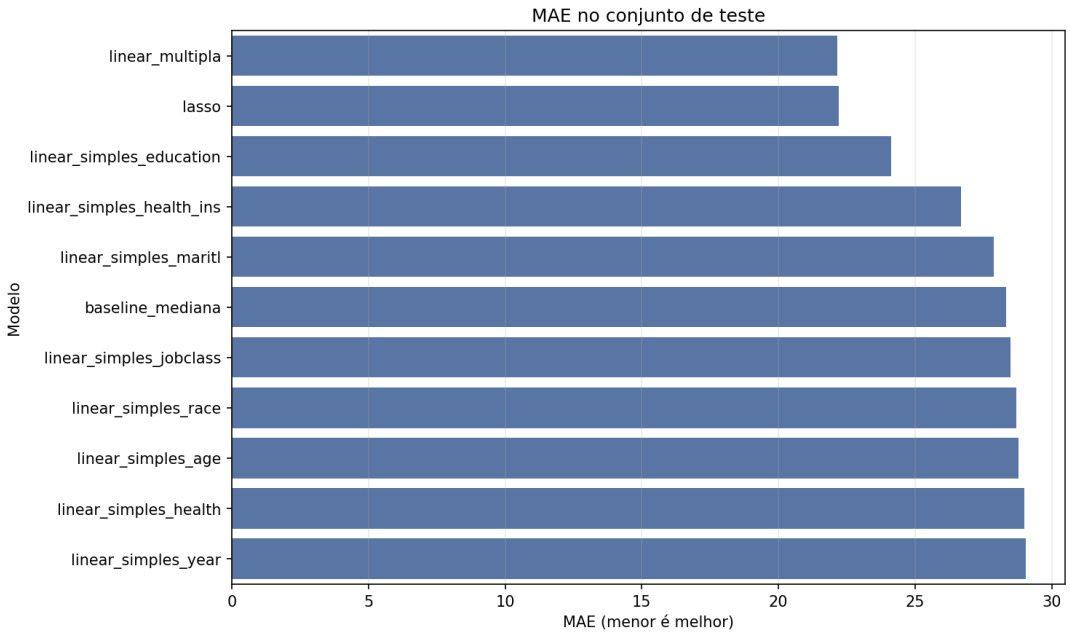



Figura 1: Comparação do MAE no conjunto de teste.

A Figura 1 evidencia a proximidade entre a regressão múltipla e o Lasso, bem como a vantagem de ambas sobre os modelos simples e o baseline. O ganho obtido pela regressão simples baseada em educação também é visível, embora seu erro ainda seja cerca de duas unidades superior ao dos modelos que combinam todas as características.

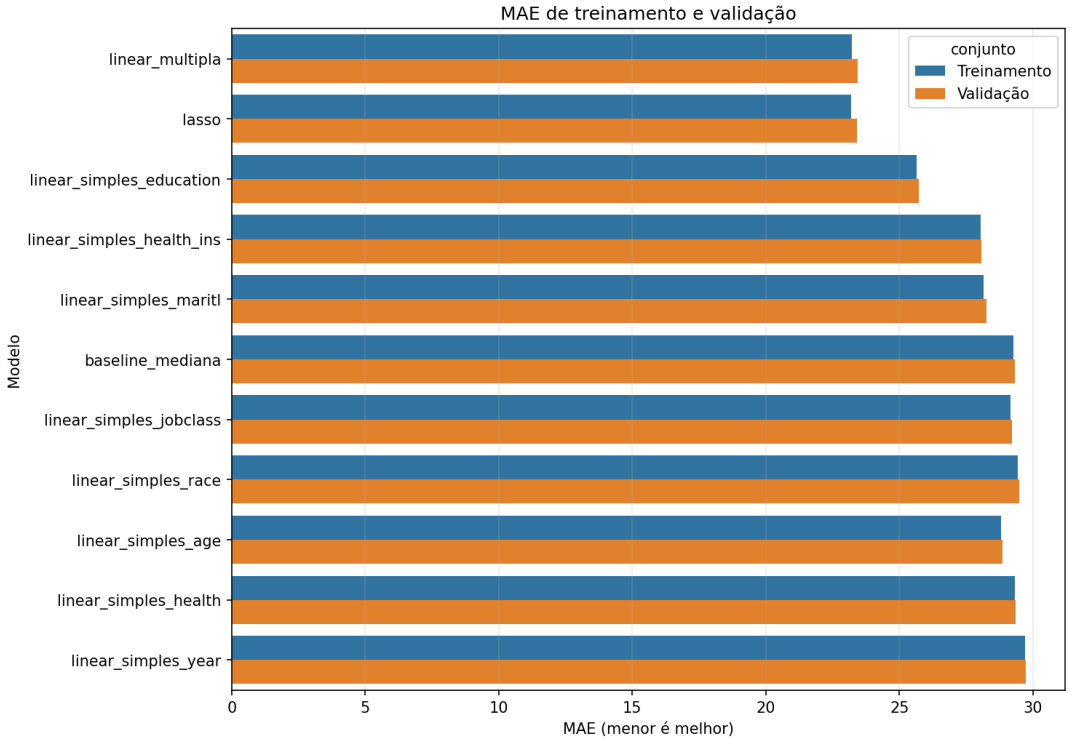



Figura 2: Comparação do MAE médio de treinamento e validação nas 15 partições.

A Figura 2 mostra diferenças pequenas entre os erros de treinamento e validação. As maiores diferenças foram observadas na regressão múltipla (0,22) e no Lasso (0,20), valores reduzidos diante da magnitude do MAE e dos respectivos desvios-padrão. Portanto, não foi identificado sinal relevante de sobreajuste nas técnicas avaliadas.

### 3.4 Análise dos Parâmetros

O melhor valor encontrado para o parâmetro de regularização do Lasso foi $\alpha = 0{,}063682$. Como mostra a Figura 3, valores muito pequenos produziram desempenho semelhante ao da regressão múltipla, enquanto penalizações elevadas aumentaram substancialmente o MAE por reduzirem excessivamente os coeficientes. A faixa sombreada representa um desvio-padrão entre as 15 avaliações de cada valor de $\alpha$.

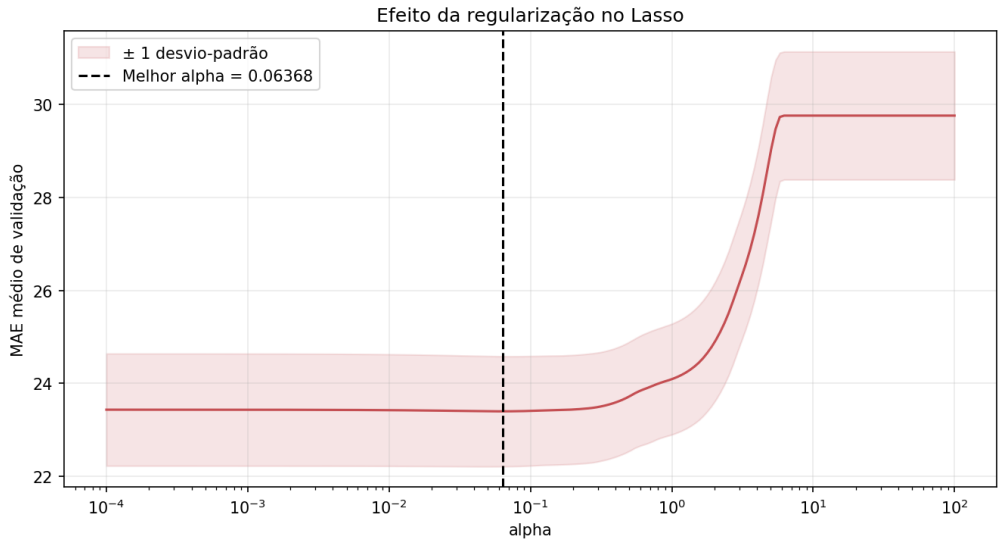



Figura 3: Relação entre o parâmetro $\alpha$ e o MAE médio de validação do Lasso.

Com o melhor $\alpha$, somente um dos 16 coeficientes foi reduzido exatamente a zero: o indicador correspondente à categoria viúvo do estado civil. Os coeficientes de maior magnitude foram associados a pós-graduação ou formação avançada (48,57), graduação universitária (27,65), idade normalizada (20,22), ausência de plano de saúde ($-17{,}24$), estado civil casado (15,49) e alguma formação universitária (13,39). Esses valores devem ser interpretados em relação às categorias de referência utilizadas na codificação.

### 3.5 Observações Adicionais

Todos os 200 valores de $\alpha$ foram avaliados sem erro de convergência. A repetição da validação reduziu a dependência de uma única partição interna, e a pequena diferença entre os resultados de treinamento e validação sugere estabilidade razoável. Entretanto, a proximidade entre a regressão múltipla e o Lasso não permite afirmar que a regularização trouxe ganho preditivo relevante neste conjunto de dados.

Educação foi a variável isolada mais informativa, mas a combinação das oito características reduziu ainda mais o erro. Ano, saúde, idade, raça e classe de emprego, quando utilizados isoladamente, não superaram o baseline no conjunto de teste ou apresentaram diferença muito pequena em relação a ele.

# 4 Conclusão

## 4.1 Conclusões Gerais

A regressão linear múltipla apresentou o melhor desempenho no conjunto de teste, com MAE de 22,14, seguida pelo Lasso, com MAE de 22,21. Ambas superaram de forma substancial o baseline baseado na mediana, cujo MAE foi 28,32. Portanto, a combinação das oito características disponíveis permitiu reduzir o erro absoluto em aproximadamente 21,8% em relação à referência ingênua.

Entre as regressões simples, educação foi a variável com maior capacidade preditiva, alcançando MAE de 24,13. O resultado mostra que essa característica concentra parte importante da informação salarial, mas também que a incorporação conjunta das demais variáveis melhora a previsão.

O Lasso selecionou $\alpha = 0{,}063682$ e zerou apenas um dos 16 coeficientes. Sua regularização não produziu vantagem relevante sobre a regressão múltipla: o Lasso foi ligeiramente melhor na validação cruzada, enquanto a regressão múltipla foi ligeiramente melhor no teste. Considerando a diferença reduzida, os modelos apresentaram desempenhos essencialmente equivalentes, e a regressão múltipla pode ser preferida por sua simplicidade e pelo menor MAE final.

## 4.2 Limitações do Estudo

Embora a validação interna tenha utilizado cinco divisões e três repetições, os resultados finais ainda correspondem a uma única divisão externa entre treinamento e teste e podem variar com outra amostra. Além disso, foram consideradas apenas relações lineares e aditivas, sem termos de interação ou transformações não lineares. A interpretação dos coeficientes também depende da normalização e das categorias de referência adotadas.

O conjunto de dados possui somente 3.000 observações e inclui características sensíveis, como raça, estado civil e saúde. Assim, o desempenho preditivo não deve ser interpretado como justificativa para decisões salariais automatizadas ou para relações causais entre essas características e o salário.

## 4.3 Considerações Finais

O estudo respondeu à pergunta de pesquisa ao demonstrar que modelos lineares conseguem prever parcialmente a variável `wage` a partir das oito características disponíveis. A regressão múltipla apresentou o menor erro de teste, enquanto o Lasso mostrou que quase todas as características conservaram alguma contribuição no modelo regularizado.

Como trabalhos futuros, podem ser avaliadas diferentes divisões externas dos dados, validação cruzada aninhada e relações não lineares. Essas extensões permitiriam verificar a estabilidade da avaliação final sem alterar a conclusão principal obtida no escopo atual.