Previsão salarial

Relatório de modelagem preditiva

Daniel Cagy · Felipe Klein · Gustavo Martins

10 de novembro de 2026

Sumário

1 Introdução **1**

1.1 Contextualização 1

1.2 Pergunta de pesquisa 1

1.3 Público-alvo 1

2 Plano de experimentação **2**

2.1 Dados de entrada 2

2.2 Técnicas utilizadas 3

2.3 Métricas 4

2.4 Parâmetros testados 4

3 Resultados **5**

3.1 Metodologia 5

3.2 Resultados 5

3.3 Visualização dos Resultados 5

3.4 Observações Adicionais 5

4 Análise dos parâmetros **6**

4.1 Análise dos Parâmetros 6

5 Conclusão **7**

5.1 Conclusões Gerais 7

5.2 Limitações do Estudo 7

5.3 Considerações Finais 7

1 Introdução

1.1 Contextualização

1.2 Pergunta de pesquisa

Este trabalho tem como objetivo responder a seguinte pergunta de pesquisa:

> *Em que medida o salário bruto pode ser previsto por modelos de regressão linear e qual das abordagens (regressão linear simples, regressão linear múltipla ou Lasso) apresenta o menor Erro Absoluto Médio?*

1.3 Público-alvo

2 Plano de experimentação

2.1 Dados de entrada

O dataset contém 8 variáveis preditoras e 1 variável alvo, que é o salário bruto.

Tabela 1: Variáveis preditoras

Variável	**Descrição**	**Tipo**
year	Ano do registro	Numérica
age	Idade do trabalhador	Numérica
maritl	Estado civil	Categórica
race	Raça	Categórica
education	Educação	Categórica
jobclass	Classe de emprego (Industrial ou Informática)	Categórica
health	Nível de saúde (bom ou muito bom)	Categórica
health_ins	Possui plano de saúde (sim ou não)	Categórica

O conjunto possui 3.000 observações e não apresenta valores ausentes. A coluna `Unnamed: 0`, presente no arquivo original, representa apenas o índice das observações e será descartada antes da modelagem. Após essa remoção, permanecem as oito variáveis preditoras e a variável alvo `wage`.

Tabela 2: Resumo da variável alvo `wage`

Estatística	**Valor**
Número de observações	3.000
Valores ausentes	0
Média	111,70
Mediana	104,92
Mínimo	20,09
Máximo	318,34
Observações além de 1,5 IQR	110
Observações além de 3 IQR	77

A média superior à mediana indica assimetria à direita na distribuição salarial. Entre as 110 observações situadas além de 1,5 IQR, 109 estão acima do limite superior e uma está abaixo do limite inferior. As 77 observações além de 3 IQR estão todas no extremo superior da distribuição. Essas observações serão mantidas, pois podem representar salários legítimos e sua remoção alteraria o problema de previsão definido pelo estudo.

As variáveis `year` e `age` serão tratadas como numéricas e normalizadas para o intervalo entre 0 e 1 pelo método Min-Max. As seis variáveis restantes serão tratadas como categóricas e convertidas em variáveis indicadoras por codificação *one-hot*, com a primeira categoria de cada variável utilizada como referência. Após essas transformações, o conjunto de preditores será composto por 16 colunas.

Após o pré-processamento, os dados serão divididos aleatoriamente em conjuntos de treinamento e teste, contendo, respectivamente, 80% e 20% das observações. Dessa forma, serão destinadas aproximadamente 2.400 observações ao treinamento e 600 ao teste. Será utilizada a semente aleatória 42 para permitir a reprodução da divisão, e o conjunto de teste será reservado para a avaliação final dos modelos.

2.2 Técnicas utilizadas

Optamos por comparar três abordagens de regressão linear para a previsão do salário bruto: regressão linear simples, regressão linear múltipla e regressão Lasso. Essa delimitação permite avaliar o ganho obtido pela combinação de variáveis e verificar se a regularização melhora o desempenho preditivo.

Regressão Linear. A regressão linear simples estima o salário a partir de uma única variável preditora. Para cada uma das oito variáveis disponíveis, será ajustado um modelo independente, permitindo avaliar isoladamente sua capacidade preditiva. A previsão é obtida pela combinação linear

$$\widehat{y}_i = \beta_0 + \beta_1 x_i, \tag{1}$$

em que $\widehat{y}_i$ é o salário previsto para o indivíduo i, x_i é o valor da variável preditora, β_0 é o intercepto e β_1 é o coeficiente associado à variável. Os coeficientes são estimados de modo a minimizar a soma dos quadrados dos resíduos entre os valores observados e previstos. Quando a variável preditora for categórica, suas categorias serão representadas por variáveis indicadoras.

Regressão Linear Múltipla. A regressão linear múltipla estende o modelo anterior ao empregar simultaneamente duas ou mais variáveis preditoras. Sua combinação linear é dada por

$$\widehat{y}_i = \beta_0 + \sum_{j=1}^{p} \beta_j x_{ij} = \beta_0 + \beta_1 x_{i1} + \cdots + \beta_p x_{ip}, \tag{2}$$

em que p representa o número de variáveis utilizadas, x_{ij} é o valor da variável j para o indivíduo i e β_j é seu respectivo coeficiente. Esse modelo permite considerar conjuntamente as informações disponíveis, embora pressuponha uma relação linear entre os preditores e o salário. As variáveis categóricas serão previamente representadas por variáveis indicadoras.

Regressão Lasso. O Lasso estende a regressão linear múltipla ao acrescentar uma penalização L_1 à função de ajuste. Os coeficientes são estimados pela minimização de

$$\sum_{i=1}^{n} (y_i - \widehat{y}_i)^2 + \alpha \sum_{j=1}^{p} \left|\beta_j\right|, \tag{3}$$

em que α controla a intensidade da regularização. Valores pequenos de α produzem resultados próximos aos da regressão linear múltipla, enquanto valores maiores reduzem os coeficientes e podem fazer com que alguns deles se tornem exatamente zero. Dessa forma, o Lasso também realiza seleção de características. Para que a penalização seja aplicada de forma comparável, serão utilizadas as variáveis previamente codificadas e normalizadas.

2.3 Métricas

O desempenho preditivo dos modelos será avaliado pelo Erro Absoluto Médio (MAE), definido por

$$\mathrm{MAE} = \frac{1}{n} \sum_{i=1}^{n} |y_i - \widehat{y}_i| \,. \tag{4}$$

Essa métrica representa a magnitude média dos erros na mesma unidade da variável salarial e possui interpretação direta. Além disso, por não elevar os resíduos ao quadrado, é menos influenciada por salários extremos. Essa característica é relevante para os dados utilizados, cuja distribuição salarial apresenta assimetria à direita. Assim, o MAE será adotado como critério para a seleção do melhor modelo: quanto menor seu valor, melhor o desempenho preditivo.

O MAE será calculado sobre observações não utilizadas no ajuste dos modelos. Na comparação por validação cruzada, serão empregadas as mesmas divisões dos dados para todas as técnicas, reportando-se a média e o desvio-padrão do MAE. Como referência, o desempenho também será comparado ao de um modelo ingênuo que prevê sempre a mediana salarial do conjunto de treinamento.

2.4 Parâmetros testados

As regressões lineares simples e múltipla não possuem hiperparâmetros. Serão ajustados oito modelos simples, um para cada variável preditora, e um modelo múltiplo contendo as oito variáveis.

No Lasso, serão testados 200 valores do parâmetro de regularização α, distribuídos uniformemente em escala logarítmica entre 10^{-4} e 10^{2}. O intervalo abrange desde penalizações quase nulas até penalizações capazes de reduzir diversos coeficientes a zero.

Cada configuração será avaliada por validação cruzada com cinco divisões, sempre com as mesmas partições, e a seleção será baseada no menor MAE médio. Ao todo, serão avaliadas 209 configurações distintas e realizados 1.045 ajustes durante a validação cruzada.

Após a seleção, a melhor configuração será reajustada com todo o conjunto de treinamento e avaliada uma única vez no conjunto de teste.

3 Resultados

3.1 Metodologia

Após o pré-processamento, os dados serão separados aleatoriamente em 80% para treinamento e 20% para teste, utilizando a semente 42. O conjunto de treinamento será empregado no ajuste e na seleção dos modelos, enquanto o conjunto de teste permanecerá reservado para a avaliação final.

No conjunto de treinamento, as configurações serão comparadas por validação cruzada com cinco divisões. Serão avaliadas oito regressões lineares simples, uma regressão linear múltipla e 200 configurações do Lasso, correspondentes aos diferentes valores de α. As mesmas divisões serão utilizadas em todas as comparações, e o desempenho será resumido pela média e pelo desvio-padrão do MAE.

Para cada técnica, será selecionada a configuração com menor MAE médio. O modelo escolhido será então reajustado com todo o conjunto de treinamento e avaliado uma única vez no conjunto de teste. Também será calculado o MAE de um modelo de referência que prevê sempre a mediana salarial do conjunto de treinamento.

3.2 Resultados

Nesta subseção serão apresentados os valores de MAE obtidos na validação cruzada e no conjunto de teste, o melhor valor de α encontrado para o Lasso e a comparação final entre as regressões simples, a regressão múltipla, o Lasso e o modelo de referência.

3.3 Visualização dos Resultados

Os resultados serão sintetizados em uma tabela contendo, para cada modelo, o MAE médio da validação cruzada, seu desvio-padrão e o MAE obtido no conjunto de teste. Também será apresentado um gráfico comparativo dos erros, facilitando a identificação do modelo com melhor desempenho preditivo.

3.4 Observações Adicionais

Nesta subseção serão registradas observações relevantes identificadas durante a execução dos experimentos, como estabilidade entre as divisões da validação cruzada, diferenças entre os desempenhos de validação e teste, possíveis problemas de convergência e características selecionadas pelo Lasso.

4 Análise dos parâmetros

4.1 Análise dos Parâmetros

5 Conclusão

5.1 Conclusões Gerais

5.2 Limitações do Estudo

5.3 Considerações Finais