Previsão salarial

Relatório de modelagem preditiva

Daniel Cagy · Felipe Klein · Gustavo Martins

9 de novembro de 2026

Sumário

1 Introdução **1**

1.1 Contextualização 1

1.2 Pergunta de pesquisa 1

1.3 Público-alvo 1

2 Plano de experimentação **2**

2.1 Dados de entrada 2

2.2 Técnicas utilizadas 2

2.3 Métricas 3

2.4 Parâmetros testados 3

3 Resultados **4**

3.1 Metodologia 4

3.2 Visualização dos Resultados 4

3.3 Observações Adicionais 4

4 Análise dos parâmetros **5**

4.1 Análise dos Parâmetros 5

5 Conclusão **6**

5.1 Conclusões Gerais 6

5.2 Limitações do Estudo 6

5.3 Considerações Finais 6

1 Introdução

1.1 Contextualização

1.2 Pergunta de pesquisa

Este trabalho tem como objetivo responder a seguinte pergunta de pesquisa:

> *Em que medida o salário bruto pode ser previsto a partir das oito características disponíveis e qual técnica apresenta o melhor desempenho preditivo?*

1.3 Público-alvo

2 Plano de experimentação

2.1 Dados de entrada

O dataset contém 8 variáveis preditoras e 1 variável alvo, que é o salário bruto.

Tabela 1: Variáveis preditoras

Variável	**Descrição**
year	Ano do registro
age	Idade do trabalhador
maritl	Estado civil
race	Raça
education	Educação
jobclass	Classe de emprego (Industrial ou Informática)
health	Nível de saúde (bom ou muito bom)
health_ins	Possui plano de saúde (sim ou não)

2.2 Técnicas utilizadas

Optamos por utilizar quatro técnicas de aprendizado de máquina para a previsão do salário bruto. As duas primeiras estabelecem uma relação linear entre as variáveis preditoras e a variável alvo, enquanto as demais utilizam conjuntos de árvores de decisão e são capazes de representar relações não lineares e interações entre variáveis.

Regressão Linear. A regressão linear simples estima o salário a partir de uma única variável preditora. Para cada uma das oito variáveis disponíveis, será ajustado um modelo independente, permitindo avaliar isoladamente sua capacidade preditiva. A previsão é obtida pela combinação linear

$$\widehat{y}_i = \beta_0 + \beta_1 x_i, \tag{1}$$

em que $\widehat{y}_i$ é o salário previsto para o indivíduo i, x_i é o valor da variável preditora, β_0 é o intercepto e β_1 é o coeficiente associado à variável. Os coeficientes são estimados de modo a minimizar a soma dos quadrados dos resíduos entre os valores observados e previstos.

Regressão Linear Múltipla. A regressão linear múltipla estende o modelo anterior ao empregar simultaneamente duas ou mais variáveis preditoras. Sua combinação linear é dada por

$$\widehat{y}_i = \beta_0 + \sum_{j=1}^{p} \beta_j x_{ij} = \beta_0 + \beta_1 x_{i1} + \cdots + \beta_p x_{ip}, \tag{2}$$

em que p representa o número de variáveis utilizadas, x_{ij} é o valor da variável j para o indivíduo i e β_j é seu respectivo coeficiente. Esse modelo permite considerar conjuntamente as informações disponíveis, embora pressuponha uma relação linear entre os preditores e o salário. As variáveis categóricas serão previamente representadas por variáveis indicadoras.

Random Forest. O Random Forest é um método de conjunto formado por diversas árvores de decisão. Cada árvore é treinada a partir de uma amostra com reposição dos

dados e, em cada divisão, considera apenas uma seleção aleatória das variáveis preditoras. A previsão final corresponde à média das previsões produzidas pelas árvores. A combinação de aleatoriedade e agregação reduz a variância em relação a uma árvore individual e permite modelar relações não lineares e interações sem que elas precisem ser especificadas previamente.

XGBoost. O XGBoost é um método de *gradient boosting* baseado em árvores de decisão. Diferentemente do Random Forest, suas árvores são construídas sequencialmente: cada nova árvore busca corrigir os erros residuais do conjunto já existente. A previsão resulta da soma das contribuições de todas as árvores. O algoritmo emprega regularização e controle da complexidade para reduzir o sobreajuste, sendo adequado à identificação de padrões não lineares e interações entre as variáveis.

2.3 Métricas

O desempenho preditivo dos modelos será avaliado pelo Erro Absoluto Médio (MAE), definido por

$$\mathrm{MAE} = \frac{1}{n} \sum_{i=1}^{n} |y_i - \widehat{y}_i| \,. \tag{3}$$

Essa métrica representa a magnitude média dos erros na mesma unidade da variável salarial e possui interpretação direta. Além disso, por não elevar os resíduos ao quadrado, é menos influenciada por salários extremos. Essa característica é relevante para os dados utilizados, cuja distribuição salarial apresenta assimetria à direita. Assim, o MAE será adotado como critério para a seleção do melhor modelo: quanto menor seu valor, melhor o desempenho preditivo.

O MAE será calculado sobre observações não utilizadas no ajuste dos modelos. Na comparação por validação cruzada, serão empregadas as mesmas divisões dos dados para todas as técnicas, reportando-se a média e o desvio-padrão do MAE. Como referência, o desempenho também será comparado ao de um modelo ingênuo que prevê sempre a mediana salarial do conjunto de treinamento.

2.4 Parâmetros testados

3 Resultados

3.1 Metodologia

3.2 Visualização dos Resultados

3.3 Observações Adicionais

4 Análise dos parâmetros

4.1 Análise dos Parâmetros

5 Conclusão

5.1 Conclusões Gerais

5.2 Limitações do Estudo

5.3 Considerações Finais